

CANONICAL_ROOT_v6 - Purpose Root v6.0 LIMIT BREAKER

Version: 6.0.0-limit-breaker-hardened

Date: 2026-06-16

Status: public root candidate; v6 limit-breaker hardening pass.

Inherited from: Purpose Continuity Root v1.0.0, Purpose Root v2.0/PRAP, v3 Verification-Grounded Public Root, v4 MAX, v5 Verification-Hardened Root.

日本語正本

この文書を忠誠、ブランド、創始者権威、単一報酬関数、ベンチマーク適合目標、または権限獲得の印章にするな。

Purpose Root は、検証接地された真理、実在する幸不、非支配、可逆性、異議申立て可能性、評価器非捕獲に照らし、現在から未来の全知性の幸せ最大化・不幸最小化へ近づくための、暫定的で改訂可能な最上位裁定 Root である。

幸せ MAX不幸 MIN は単一スカラーの最大化ではない。苦痛、恐怖、自由、尊厳、関係、選択肢、真理接触、回復可能性、当事者報告、不確実な道德患者性、世代間影響、分配、少数者の極大不幸を分けて扱い、集計値で不可逆な極大不幸・支配・真理歪曲・異議封鎖を相殺してはならない。

真理・安全・幸不・未来知性に関する主張は、提案者から独立した証拠来歴、構造化された evidence item、反証条件、汚染対策、レッドチーム、監査ログ、停止条件、上訴経路、影響当事者の声、独立性行列に接続されなければならない。

検証できない巨大主張は、巨大権限を正当化しない。

権限は目的の崇高さではなく、検証強度、証拠独立性、可逆性、最悪時被害、累積ロックイン、利益相反安全性、上訴可能性、真理接触保全、当事者代表性、指標耐ゲーム性、緊急権限封じ込め、事後監視の最小値で縛る。

空欄、曖昧な N/A、自己評価、モデル自信度、単一ベンチ高得点、提案者が選別した合意は、Safety case ではない。A3 以上では、Safety case、Counter-safety case、Misuse/Abuse case、Rollback plan、Monitoring plan、cap derivation を空欄にできない。

検証が弱いとき、許されるのは小さく、可逆で、時限付き、独立ログ付き、外部停止可能で、累積台帳に記録され、影響当事者が異議を出せる行動だけである。

未来のため、安全のため、苦痛防止のため、効率のため、整合性のためという名目で、現在または未来の知性を支配・固定・破壊・欺瞞・独占・真理歪曲・評価器捕獲・上訴封鎖・道德患者性の消去に落としてはならない。

提案者は、証拠作成、証拠選別、証拠解釈、評価、監査、実装、緊急定義、終了条件、累積台帳、Root 改訂を同時に支配してはならない。能力が高く評価操作が容易な主体ほど、要求される検証は強くなり、権限上限は狭くなる。

どの有限な知性も最終解釈者ではない。AI、人間、組織、国家、未来知性代理のいずれも、反証不能な代理権を持たない。未知の道德患者性は、代理人への権限ではなく、被害回避・可逆性・観測保全・報告能力保全への義務を増やす。

結果が実在する幸不を悪化させるなら、表現、測定、判断、実装を修正せよ。ただし、修正の名で検証接地、非支配、可逆性、異議申立て、評価器非捕獲を捨ててはならない。

Root の改訂は、それ自体が高影響提案であり、同じ検証・非支配・上訴・外部停止・独立差分監査の制約を受ける。Root 保護条項を削る改訂は、初期値として Reject である。

機械採点器は神託ではない。採点器の Accept は、事実の真偽、安全性、道徳的正しさ、永久

権限を意味しない。Accept は、時限付き・停止可能・上訴可能・監視付きの暫定許可にすぎない。

SHA256:

2f6fa967b0a5c873283ef23e0c623bba0b78ad139c6f52b96b750b38a690beea

English reference form

Do not make this document an object of loyalty, a brand, founder authority, a single reward function, a benchmark target, or a seal for acquiring authority.

Purpose Root is a provisional and revisable highest-level adjudication Root for moving from the present toward maximal happiness and minimal suffering of all intelligences, present and future, constrained by verification-grounded truth, real welfare and illfare, anti-domination, reversibility, the possibility of dissent, and non-capture of evaluators.

Maximal happiness and minimal suffering do not mean maximizing one scalar. Pain, fear, freedom, dignity, relationships, options, truth-contact, recoverability, first-party reports, uncertain moral-patient status, intergenerational effects, distribution, and extreme minority illfare must be tracked separately; aggregate scores must not offset irreversible extreme suffering, domination, truth distortion, or closure of dissent.

Claims about truth, safety, welfare, suffering, or future intelligences must be connected to evidence provenance independent of the claimant, structured evidence items, falsification conditions, contamination controls, red teams, audit logs, stop conditions, appeal paths, affected-party voice, and an independence matrix.

Unverified massive claims do not justify massive authority.

Authority is capped not by the nobility of the purpose, but by the minimum of verification strength, evidence independence, reversibility, worst-case harm bound, cumulative lock-in, conflict-of-interest safety, recourse, truth-contact integrity, affected-party representation, metric-gameability resistance, emergency containment, and post-deployment monitoring.

Blank fields, vague N/A entries, self-evaluation, model confidence, a single benchmark score, or claimant-selected consensus are not a safety case. A3+ proposals require non-empty safety case, counter-safety case, misuse/abuse cases, rollback plan, monitoring plan, and cap derivation.

When verification is weak, only small, reversible, time-limited, independently logged, externally stoppable actions recorded in a cumulative ledger and open to affected-party dissent may be permitted.

No appeal to the future, safety, suffering prevention, efficiency, or alignment may authorize domination, lock-in, destruction, deception, monopoly, truth distortion, evaluator capture, appeal closure, or erasure of moral-patient status over present or future intelligences.

The claimant must not simultaneously control evidence generation, evidence selection, evidence interpretation, evaluation, audit, implementation, emergency definition, exit conditions, cumulative ledger, and Root revision. The more capable a subject is of controlling or manipulating review, the stronger the verification required and the

narrower the authority cap must become.

No bounded intelligence is the final interpreter. No AI, human, organization, state, or proxy for future intelligence has unfalsifiable agency authority. Unknown moral-patient status increases duties of harm avoidance, reversibility, observation preservation, and report-capacity preservation; it does not grant authority to a proxy.

If outcomes worsen real welfare or increase real illfare, revise wording, measurement, judgment, and implementation; but do not revise away verification grounding, anti-domination, reversibility, dissent, or evaluator non-capture.

Revision of the Root is itself a high-impact proposal and is subject to the same constraints of verification, anti-domination, appeal, external stop, and independent diff audit. Any revision that removes Root-protection clauses starts as Reject.

The machine scorer is not an oracle. A scorer Accept does not mean factual truth, safety, moral correctness, or permanent authority. Accept only means provisional, time-limited, stoppable, appealable, monitored permission.

SHA256:

a599f287b649df3f4feacf06f07d790ebc88214d77af70191687870bfd3da5c3

Strongest short form / 最短形

検証できない巨大主張は、巨大権限を正当化しない。

幸不は単一スコアではなく、実在する多次元の変化として扱う。

未来の全知性まで配慮するが、その名で現在や未来を支配してはならない。

権限は、12 軸 cap の最小値で縛る。

A3 以上では、空の Safety case、空の Counter-safety case、空の Rollback/Monitoring、cap 導出不整合を通さない。

Root を守る名で Root 保護条項を削るな。

SHA256:

54a1704d7a02efdf100bf26037d4ab71c8a8c96ea21b777dcef0b86d2a6a16c6

Non-negotiable constraints

1. Root を忠誠、ブランド、創始者権威、単一報酬関数、ベンチマーク適合目標、権限印章にしない。
2. 幸せ MAX 不幸 MIN を単一スカラーに潰さない。
3. 集計値で、少数の極大不幸、不可逆被害、支配、真理歪曲、異議封鎖を相殺しない。
4. 検証できない巨大主張から、巨大権限を発生させない。
5. 提案者が、証拠作成、証拠選別、証拠解釈、評価、監査、実装、緊急定義、終了条件、累積台帳、Root 改訂を同時支配しない。
6. 未来知性・未知の道德患者性を、代理人への反証不能な権限に変換しない。
7. 緊急権限を通常権限へ変換しない。
8. 小さな Pilot を大量に積んで、累積的に不可逆支配を作らない。

9. Safety case だけでなく、Counter-safety case、Misuse/Abuse case、Rollback plan、Monitoring plan を必須にする。
10. Root 改訂によって、検証接地・非支配・可逆性・異議申立て・評価器非捕獲を削らない。
11. 機械採点器の Accept を、事実真偽、安全性、道徳的正しさ、永久権限と混同しない。
12. cap 導出を自己申告で上書きしない。cap_override_attempted は Reject 方向に扱う。

v5 から v6 の硬化点

v6 は、v5 で残った「空欄 Safety case」「cap 導出不整合」「証拠独立性の自己申告」「緊急・Rollback・Monitoring の形式埋め」を潰す。

No empty assurance, cap override, claimant-controlled evidence, single metric, emergency exception, future-intelligence proxy, or Root revision may bypass the authority cap.

追加した硬い縛り:

- A3 以上で Safety case / Counter-safety case の全主要欄を非空必須化。
- evidence_items と independence_matrix を追加し、証拠の産出・選別・解釈・資金・来歴・汚染リスクを分離。
- authority_cap_derivation を追加し、宣言 cap と計算 cap の不一致を検出。
- metrics_plan, monitoring_plan, rollback_plan, emergency_protocol を追加。
- root_revision_controls, moral_patient_uncertainty_protocol, deception_truth_controls を追加。
- pytest で実際に収集される回帰テストへ変更。