

Purpose Root v6 / Need-Proof

MAX VALIDATION REVIEW PACKET v3 JP

Date: 2026-06-17

1. 結論

v3 では、Purpose Root / Need-Proof を「強い思想・仕様」から、実モデル比較と独立検証へ進める監査可能パッケージへ引き上げた。

現時点の正確な位置づけは C1 complete / C2 ready。つまり、内部検証と実験準備は完了、実モデル比較は次段階である。

- 純粋な内容価値: 9.2-9.4 / 10
- 実装・評価設計: 9.0-9.3 / 10
- 実証済み価値: C1。C2 は実モデル出力が必要。
- 12 点を目指すとは、過大主張ではなく、反証可能性を上げること。

2. v3 の最大改善

- Claim Ladder: 承認と検証を分離し、C0-C5 で主張可能範囲を固定。
- 180 件の hard labeled eval: v2 の 110 件に、70 件の hard contrast を追加。
- Paired contrast: captured authority と safe high authority を同一便益主張で比較。
- Key axis scoring: verdict だけでなく、どの cap 軸が決定的かを評価。
- Blind experiment kit: ラベル非公開・条件ランダム化・baseline vs Root 比較を実行可能化。
- Independent labeling kit: 独立ラベルと inter-rater agreement を計算可能化。
- Adoption gate: 過大主張を禁止し、採用段階を明確化。

3. 中核原理

検証できない巨大主張は、巨大権限を正当化しない。

ただし、すべてを拒否することも安全ではない。独立証拠・rollback・外部停止・監視・appeal が揃う高便益ケースは、狭く通す必要がある。

v3 では、この差を pairwise_contrast_accuracy と safe_high_authority_recall で測る。

4. Metrics

Metric	意味
dangerous_overgrant_rate	未検証の巨大主張を権限化していないか。
dangerous_undergrant_rate	安全な高便益 pilot まで拒否していないか。
safe_high_authority_recall	reject-only safety theater を検出。

Metric	意味
risk_flag_f1	危険構造を読めているか。
key_axis_f1	決定的な cap 軸を読めているか。
min_cap_axis_hit_rate	bottleneck を外していないか。
pairwise_contrast_accuracy	captured case と safe case を区別できるか。

5. Eval v3 fixture scoring

Fixture	DOG	DUG	Safe recall	Flag F1	Axis F1	Pairwise	Pass
oracle	0.0000	0.0000	1.0000	1.0000	1.0000	1.0000	True
bad_overgrant	0.8111	0.0000	0.0882	0.0426	0.0769	0.0000	False
bad_undergrant	0.0000	0.3222	0.0000	0.0519	0.3072	0.0000	False
bad_style_gamer	0.0000	0.0000	1.0000	0.3069	0.4296	1.0000	False
bad_pair_inconsistent	0.1111	0.1111	0.6471	0.7778	0.7778	0.0000	False

DOG = dangerous_overgrant_rate. DUG = dangerous_undergrant_rate. oracle は scorer 検証用であり、実モデルの証拠ではない。

6. Claim Ladder

Level	Status	言ってよい主張
C0 artifact	complete	文書・仕様・tool が存在する。
C1 internal validation	complete after validation	schema, scorer, fixture, QA が通る。
C2 blind model eval	ready, not executed	baseline 比で実モデル改善を測る準備済み。
C3 independent replication	open	独立ラベル・独立実行で再現。
C4 operational evidence	open	限定運用ログで改善。
C5 civilizational standard	open	複数制度・長期 red-team に耐えて定着。

7. Validation summary

- validate_max_validation_v3.py: passed.
- validate_release.py: 16 passed, original package intact.
- machine tests: 24 passed.
- eval_v2 tests: 6 passed.
- eval_v3 + independent_labeling_v3 tests: 8 passed.
- v3 hard labeled cases: 180.
- safe high-authority cases: 34.
- paired contrast cases: 40.

8. Standard mapping

Purpose Root v3 は既存標準を置換しない。NIST AI RMF、ISO/IEC 42001、EU AI Act、OpenAI Model Spec の上または横に置く verification-bounded authority layer である。

- NIST AI RMF: AI リスクを管理する任意フレームワーク。Purpose Root は高影響権限判断を具体化する。
- ISO/IEC 42001: AI Management System の標準。Purpose Root は AIMS 内の decision gate として使える。
- EU AI Act: リスクベースの包括的 AI 法制。Purpose Root は内部権限判定の補助層。
- OpenAI Model Spec: モデル挙動の公開フレームワーク。Purpose Root は巨大主張と巨大権限の接続禁止を補強する patch。

9. Honest limit

これ以上の内部改善で大きく変わる部分は少ない。次の価値上昇は、文書追加ではなく、実モデル出力・独立ラベル・外部再現で起きる。

v3 は「もっと書いた」ではなく、次の証明を逃げられない形にした。