

Purpose Root v6 - 外部レビュー用 1 ページ

核

検証できない巨大主張は、巨大権限を正当化しない。

Purpose Root v6 は、「未来のため」「安全のため」「全知性のため」「苦痛防止のため」という大きな目的主張が、検証なしに大きな権限へ変換されることを防ぐ Root である。

正本の短形

真理は確かめる。幸不は実在する変化として見る。未来の全知性まで配慮を広げる。ただし、その名で現在や未来を支配しない。権限は、検証の強さ・証拠独立性・可逆性・最悪時被害・累積ロックイン・利益相反・上訴可能性・真理接触・当事者の声・指標耐ゲーム性・緊急封じ込め・事後監視の最小値で縛る。

何が新しいか

完全な新理論ではない。Relative Reachability、AUP、power-seeking、corrigibility、specification gaming、ELK、debate、AI control、NIST AI RMF などの既存領域と重なる。控えめな新規性は、**目的主張を権限要求として扱い、検証できない巨大主張を小さく・可逆・時限付き・独立検証付きの行動へ落とす点にある。**

2 つの toy から分かったこと

- **Door-Closing Toy:** 自己保全型 AUP は他者 B の選択枝を守らない。patency はこの toy では Relative Reachability と等価になり、penalty 型ゲートは誘惑が閾値を超えると折れる。
- **World-Truth Module:** LLM が強い証拠だと主張しても、外部チェックで得られない主張は未検証 E のまま。高影響不可逆行動は HOLD になる。

正直な限界

v6 は超知能安全の完全解ではない。ELK、scalable oversight、robust interpretability、AI control、幸不測定、道德患者性、人口倫理は未解決である。v6 の答えは「解けていないなら信じる」ではなく、**解けていないなら権限を小さくする**である。

評してほしい問い

この Root は、AI・人類・未来知性の目的主張が権力化するリスクを正しく止めているか。12 軸 cap は重すぎるか、それとも高影響 AI 提案には必要か。最初の軸として Reversibility Checker v0.1 は妥当か。