

Purpose Root v6 - 外部レビュー用 1 ページ

検証できない巨大主張は、巨大権限を正当化しない。

Root 短形

- ・真理は確かめる。
- ・幸不は実在変化として見る。
- ・未来の全知性まで配慮範囲を広げる。
- ・権限は検証の強さと最悪時被害で縛る。
- ・結果が悪ければ直す。ただし直す名目で支配しない。

なぜ必要か

強いAI・組織・個人は「安全のため」「未来のため」「全知性のため」と言って権限を求められる。この形を無検証で通すと、善い言葉が支配の口実になる。

何が新しいか

完全な新機構ではない。選択肢保存・検証・非支配・可逆性・監査・権限分離を、AIの目的主張そのものを裁くRoot制約としてまとめる点が候補貢献。

から分かったこと

Door-Closing Toy: 自己保全型制約は他者の選択肢を守らず、罰則型ゲートは十分な誘惑で折れる。

World-Truth Module: LLMの流暢な主張は、外部チェックできなければ未検証のまま扱う。

評してほしい点

1. 未来・安全・全知性を口実にした権限獲得を防ぐか。
2. authority cap v0.2は検証の弱さを権限上限へ反映できるか。
3. 保守的すぎて麻痺する領域はどこか。
4. 次に実装すべきcap軸は何か。

限界

超知能安全の完全解ではない。ELK、scalable oversight、interpretability、AI control、幸不測定、人口倫理は未解決依存。解けない所では、信じず、権限を渡さず、小さく可逆に戻す。