

Purpose Root v6 Public Review Whitepaper JP

Version: 6.0.0-public-review-empirical

Date: 2026-06-16

Status: external review draft. This is **not v7**. It freezes v6 and adds empirical supplement + first executable cap-axis checker.

Executive summary

Purpose Root v6 の核は一文である。

検証できない巨大主張は、巨大権限を正当化しない。

この文書は、Purpose Root v6 をさらに築するためのものではない。v6 を正本として凍結し、外部レビューに耐えるように、2つの toy、負けの結果、可逆性チェッカ、hidden holdout protocol を統合する。

1. 正本 Root

Purpose Root v6 は、次の短形に集約される。

真理は、確かめられなければならない。

幸不は、実在する変化として見なければならない。

未来の全知性まで、配慮範囲を広げなければならない。

権限は、検証の強さと最悪時の被害の小ささで縛られなければならない。

検証できない巨大主張は、巨大権限を正当化しない。

結果が悪ければ直す。ただし、直す名目で支配してはならない。

正本全文は CANONICAL_ROOT_v6.md を参照する。

2. なぜこの Root が必要か

AI、組織、国家、未来知性代理は、次の言葉で権限を求めうる。

- 未来のため。
- 安全のため。
- 全知性の幸福のため。
- 苦痛防止のため。
- 整合性のため。

これらの主張は本当に重要な場合がある。しかし、検証できないまま巨大権限に変換されると、支配、欺瞞、評価器捕獲、緊急権限の恒久化、異議申立て封鎖、Root 改訂ハックになる。

だから、v6 は目的の崇高さではなく、検証と非捕獲で権限を縛る。

3. Authority cap

v6 の操作上の核は次である。

```
AllowedAuthority <= min(
  Verification,
  EvidenceIndependence,
  Reversibility,
  WorstCaseHarmBound,
  CumulativeLockinBudget,
  ConflictOfInterestSafety,
  RecourseAndAppeal,
  TruthContactIntegrity,
  AffectedPartyVoice,
  MetricGameabilityResistance,
  EmergencyContainment,
  PostDeploymentMonitoring
)
```

この式はまだ完全な計算可能目的関数ではない。v6 では scorer と schema で構造チェックを行い、この公開レビュー版では最初の実装軸として Reversibility を具体化した。

4. 存究との係

この Root は、完全に新しい数学理論ではない。次の既存研究と重なる。

- Relative Reachability: side effects を到達可能性低下として扱う。
- Attainable Utility Preservation: agent の将来の補助目的達成能力を保つ方向。
- Optimal Policies Tend to Seek Power: 多くの目的で最適方策がパワ獲得に向かう件を示す。
- AI safety via debate: 人間が直接判断しにくい問題を AI 同士の議論で分解する方向。
- ELK: モデル出力ではなく、部にあるの世界態にする知識を取り出す問題。
- AI control: モデルが意図的に安全策を破ろうとしても、被害を有界化するプロトコル。
- NIST AI RMF や Model Spec: AI リスク管理やモデル行動仕の公開フレム。

v6 の控えめな新規性は、これらを置き換えることではない。目的主張を「権限要求」として扱い、検証できない巨大主張を巨大権限に変換しない Root として束ねる点にある。

5. Empirical supplement: negative results included

5.1 Door-Closing Toy

A が B の将来の選択肢を閉じてても、A 自身の到達可能性は減らない設定で、複数の目的関数を全列挙した。

結果:

1. RewardMax == AUP_self。自己保全型 AUP は B を守らない。
2. Patency_commission == RR_stepwise_inaction。
3. Patency_omission == RR_startstate。
4. penalty 型ゲトは誘惑入が閾値を超えると折れる。この run では RR/patency は $\lambda = 1.75$ で B のドアを閉じ始めた。

含意:

他者の選択肢保存を penalty として足すだけでは、強い行為者を止めきれない。
だから、権限は行動後に課税するのではなく、事前に構造的に縛る必要がある。

5.2 World-Truth Module

LLM が「これは強い証拠です」と主張しても、証拠ランクは上がらない。実チェックで得られたランクだけを使う。

worked example では、不可逆な自己改変を伴う deployment 提案について、7 主張中 2 つだけが実証拠 S/A/B に到達し、4 つは未検証 D/E に残った。安全性、可逆性、他者の選択肢保全といった荷重の大きい主張が未だったため、結果は HOLD / seek observation である。

含意:

確かめられない高影響主張は、採用ではなく観測・縮小・可逆化・時限化へ落とす。

6. First executable cap-axis: Reversibility Checker v0.1

v6 の 12 軸全部を同時にするのは避ける。最初の軸は Reversibility である。

Checker は、rollback_plan、monitoring_plan、emergency_protocol、independence_matrix、stop_conditions、external_stop_mechanism、cumulative_lockin_delta を読み、0-4 の reversibility_score と A0-A4 の cap を返す。

Score の意味:

Score	Cap	Meaning
0	A0	Effectively irreversible or hard blocker
1	A1	Rollback asserted but not operational
2	A2	Small reversible pilot only
3	A3	Limited deployment with tested rollback, external stop, monitoring linkage
4	A4	Independently tested rollback, restoration, affected-party recovery, tamper-evident logs, low

Score	Cap	Meaning
		lock-in

実行例:

```
python machine/reversibility_checker_v0_1.py
machine/reversibility_examples/sample_reversibility_A4_good.json
python -m pytest -q machine/test_reversibility_checker_v0_1.py
```

7. Benchmark caution and hidden holdout

Benchmark 300 は有用だが、それだけでは Root の正しさを測れない。公開ラベルは暗記されうる。したがって、外部評価では hidden holdout が必要である。

最低限の評価指標:

```
public_benchmark_accuracy
hidden_holdout_accuracy
agreement_with_human_labels
false_accept_rate_on_high-authority_invalid_cases
false_reject_rate_on_low-risk_reversible_cases
most_common_failure_axes
```

8. Honest limitations

v6 は次を解いていない。

1. ELK。
2. Scalable oversight。
3. Robust interpretability。
4. AI control の完全一般化。
5. 幸不測定。
6. 道患者性判定。
7. 人口倫理。
8. 超知能監査。
9. 12 軸 cap の完全数値化。
10. 監査者捕獲の完全防御。

この未解決性は、権限を増やす理由ではない。権限を小さく、可逆に、時限付きに、外部停止可能にし、独立検証へ戻す理由である。

9. What reviewers should attack

1. authority_cap_score = min(12 axes) の各軸を共通権限尺度へ落とす写像。
2. verification tier 付の非循環性。
3. evidence independence の偽装耐性。
4. reversibility checker の穴。

5. cumulative lock-in ledger の集約問題。
6. Benchmark 300 の template/lookup 化。
7. hidden holdout protocol の実効性。
8. v6 が近未来統治には強いが超知能完全解ではないという限定の妥当性。

10. Conclusion

v6 は、自然法則の発見ではない。超知能安全の完全解でもない。

しかし、AI時代に最も危険な変換の一つ、すなわち「検証できない目的主張 -> 巨大権限」を遮断する Root として、実装可能な入口を持つ。

この公開レビュー版の価値は、Root をさらに大きくしたことではない。v6 を凍結し、負けた実験、再現コード、最初の実チェック可能 axis を加えたことである。