

Purpose Root v6 Whitepaper JP

要旨

Purpose Root v6 は、巨大な目的主張を巨大権限へ変換させないための上位 Root 設計である。v5 の思想を維持しつつ、A3 以上で残っていた空 Safety case、cap 水増し、証拠独立性の自己申告、緊急例外、監査・rollback・monitoring の形式埋めを機械的に検出する。

中核は一文で足りる。

検証できない巨大主張は、巨大権限を正当化しない。

1. 問題

AI、組織、国家、未来知性代理は、次の言葉で権限を求めうる。

- 未のため。
- 安全のため。
- 全知性の幸福のため。
- 苦痛防止のため。
- 整合性のため。

この形式の主張は重要な場合もある。しかし、できないまま巨大限へ換すると、支配、欺瞞、上訴封鎖、評価器捕獲、Root 改訂ハックへ進む。

2. v6 の答え

目的の崇高さではなく、検証と非捕獲で権限を縛る。

$\text{authority_cap_score} = \min(12 \text{ axes})$

12 軸は、検証、証拠独立性、可逆性、最悪時被害、累積ロックイン、利益相反安全性、上訴、真理接事者、指標耐ゲム性、緊急封じめ、事後監視である。

3. v6 の新規貢献

v6 は、v5 から次を強化した。

1. A3 以上の空欄 Safety case 遮。
2. Safety case と Counter-safety case の両面義務化。
3. evidence_items によるごとの立性分解。
4. independence_matrix による提案者支配の明示。
5. authority_cap_derivation による cap 水増し検出。
6. emergency_protocol, rollback_plan, monitoring_plan による形式埋め対策。

7. `moral_patient_uncertainty_protocol` により、未知の道德患者性を代理権ではなく保護義務へ換。
8. `deception_truth_controls` により、報告能力消去と真理接触破壊を拒否。
9. `pytest` で実際に走る回帰テスト。
10. 300 件の seed benchmark。

4. 未来知性への貢献

v6 は未来知性を無視しない。しかし、未来知性を口実にした現在・未来への支配も許さない。

未知の道德患者性は、代理人の権限ではなく、被害回避、可逆性、観測保全、報告能力保全への義務を増やす。

5. 限界

v6 は完全な超知能安全解ではない。ELK、scalable oversight、robust interpretability、AI control、幸不測定、道德患者性判定は未解決である。

しかし、その未解決性は権限を増やす理由ではない。未解決性は、権限を小さく、可逆に、時限付きに、外部停止可能に戻す理由である。

6. 結論

v6 は、AI 時代の「善意の権力化」を止めるための Root 候補である。自然法則の見ではなく、未来の人類・AI・新知性社会で必要になる権限制御プロトコルである。